胡傲东

18085741680 hu.aodong@icloud.com GitHub 个人主页

核心竞争力

AI 研发工程师，专注于 Retrieval-Augmented Generation (RAG) 架构、Large Language Model (LLM) agent 设计与多模态应用落地，具备从知识库构建、模型调优到推理服务部署的完整链路经验。擅长围绕真实业务场景设计 GraphRAG、Tool Calling、推理调度、缓存复用与离线/在线协同策略，提升问答准确性、系统稳定性与资源利用率。具备端云协同落地经验，可将 Qwen 系列模型、Stable Diffusion、Stable Video Diffusion 与 Text-to-Speech 能力封装为可扩展服务，并结合 NPU 加速实现边缘推理。

Python | LLM Agents | RAG / GraphRAG | Supervised Fine-Tuning | 多模态推理 | 端云协同

教育背景

华中科技大学 · 集成电路设计与集成系统（本科） 2022.09 - 2026.06

专业技能

模型与框架
Python、PyTorch、FastAPI、Qwen、Stable Diffusion、Stable Video Diffusion、Text-to-Speech

RAG 与 AGENT
Retrieval-Augmented Generation (RAG)、GraphRAG、Large Language Model (LLM) agents、Tool Calling、Prompt Engineering、知识库构建

调优与推理
Supervised Fine-Tuning (SFT)、模型服务化、异步推理链路、缓存复用、限流调度、断点恢复

端云协同与部署
Docker、Linux、NPU acceleration、边缘推理、端云协同、服务部署落地

数据与系统
Redis、Asynq、MySQL、MinIO、多模态任务编排、推理服务接口设计

项目经历

端到端 AI 视频生成系统（跨平台多模态任务平台） ↗ 全栈

字节剪映 · 工程营实习生小组长（多模态 AI 核心开发） · 2025.11 - 至今

项目定位：将“文本直接生成视频”的粗放式流程重构为脚本理解、结构化分镜、提示词编译、多模型执行和视频合成五阶段链路，在 8GB 显存下稳定生成 30s 720p 视频，并降低脚本与画面漂移
架构取舍：放弃单轮大模型自由生成长视频脚本的方案，因为该方案在长文本场景下容易放大 hallucination、分镜跳变和角色设定不一致；改为由 Qwen 先生成结构化分镜，再驱动 Stable Diffusion、Stable Video Diffusion 与 Text-to-Speech 分阶段执行
机制设计：将 Prompt 编译、模型调用、素材落盘与合成导出纳入统一任务抽象，结合 Redis + Asynq 优先级调度、令牌桶限速与缓存复用，在异构模型混部场景下控制显存竞争，内存峰值降低 30%
工程结果：FastAPI 推理服务支持多模型并行编排与断点恢复，长任务恢复率 95%+；分层缓存减少重复 Stable Diffusion 推理，缓存复用率从 25% 提升至 65%，同时把端侧预览帧率从 30fps 提升至 60fps
技术栈：Qwen · Stable Diffusion · Stable Video Diffusion · Text-to-Speech · FastAPI · Go/Gin · Redis/Asynq · Docker · FFmpeg

AI 智能教学平台 ↗ 全栈

本科毕业设计 · AI 核心开发 · 2025.11 - 至今

项目定位：围绕高校教学场景构建学生中心的 AI 系统，把个性化答疑、智能批改与学情分析统一到可追踪的 RAG + Agent 链路中，在 200+ 研究生试点中将专业问答准确率提升至 85%+
架构取舍：面对跨课程知识跳转与学生个体差异，放弃“向量检索 + 单轮 Prompt”方案，因为该方案难以处理多跳推理与学情上下文；改为 GraphRAG 组织课程知识、Tool Calling 查询学生画像与学习记录，再由 Qwen3 生成个性化回答
机制设计：将检索、学情查询、答案生成与批改判定拆为可观测子步骤，并通过 Supervised Fine-Tuning 强化专业领域表达，降低 hallucination 与知识点错配；作业批改覆盖 80% 常见题型
端云协同：在桌面端接入 NPU 加速本地推理，实现离线智能答疑；云端保留 FastAPI 推理服务与知识库更新链路，使本地低时延交互与中心化模型迭代能够协同演进
技术栈：Qwen3 · GraphRAG · Supervised Fine-Tuning · Large Language Model Agent / Tool Calling · NPU acceleration · FastAPI · Python