胡傲东

18085741680 hu.aodong@icloud.com GitHub 个人主页

核心竞争力

AI 研发工程师，专注于 Retrieval-Augmented Generation (RAG) 架构、Large Language Model (LLM) agent 设计与多模态应用落地，具备从知识库构建、模型调优到推理服务部署的完整链路经验。擅长围绕真实业务场景设计 GraphRAG、Tool Calling、推理调度、缓存复用与离线/在线协同策略，提升问答准确性、系统稳定性与资源利用率。具备端云协同落地经验，可将 Qwen 系列模型、Stable Diffusion、Stable Video Diffusion 与 Text-to-Speech 能力封装为可扩展服务，并结合 NPU 加速实现边缘推理。

Python | LLM Agents | RAG / GraphRAG | Supervised Fine-Tuning | 多模态推理 | 端云协同

教育背景

华中科技大学 · 集成电路设计与集成系统（本科） 2022.09 - 2026.06

专业技能

模型与框架

Python、PyTorch、FastAPI、Qwen、Stable Diffusion、Stable Video Diffusion、Text-to-Speech

RAG 与 AGENT

Retrieval-Augmented Generation (RAG)、GraphRAG、Large Language Model (LLM) agents、Tool Calling、Prompt Engineering、知识库构建

调优与推理

Supervised Fine-Tuning (SFT)、模型服务化、异步推理链路、缓存复用、限流调度、断点恢复

端云协同与部署

Docker、Linux、NPU acceleration、边缘推理、端云协同、服务部署落地

数据与系统

Redis、Asynq、MySQL、MinIO、多模态任务编排、推理服务接口设计

项目经历

端到端 AI 视频生成系统（跨平台多模态任务平台） ↗ 全栈

字节剪映 · 工程营实习生小组长（多模态 AI 核心开发） · 2025.11 - 至今

项目定位：将“文本直接生成视频”的粗放式流程重构为脚本理解、结构化分镜、提示词编译、多模型执行和视频合成五阶段链路，在 8GB 显存下稳定生成 30s 720p 视频，并降低脚本与画面漂移

架构取舍：放弃单轮大模型自由生成长视频脚本的方案，因为该方案在长文本场景下容易放大 hallucination、分镜跳变和角色设定不一致；改为由 Qwen 先生成结构化分镜，再驱动 Stable Diffusion、Stable Video Diffusion 与 Text-to-Speech 分阶段执行

机制设计：将 Prompt 编译、模型调用、素材落盘与合成导出纳入统一任务抽象，结合 Redis + Asynq 优先级调度、令牌桶限速与缓存复用，在异构模型混部场景下控制显存竞争，内存峰值降低 30%

工程结果：FastAPI 推理服务支持多模型并行编排与断点恢复，长任务恢复率 95%+；分层缓存减少重复 Stable Diffusion 推理，缓存复用率从 25% 提升至 65%，同时把端侧预览帧率从 30fps 提升至 60fps

技术栈：Qwen · Stable Diffusion · Stable Video Diffusion · Text-to-Speech · FastAPI · Go/Gin · Redis/Asynq · Docker · FFmpeg

AI 智能教学平台 ↗ 全栈

本科毕业设计 · AI 核心开发 · 2025.11 - 至今

项目定位：围绕高校教学场景构建学生中心的 AI 系统，把个性化答疑、智能批改与学情分析统一到可追踪的 RAG + Agent 链路中，在 200+ 研究生试点中将专业问答准确率提升至 85%+

架构取舍：面对跨课程知识跳转与学生个体差异，放弃“向量检索 + 单轮 Prompt”方案，因为该方案难以处理多跳推理与学情上下文；改为 GraphRAG 组织课程知识、Tool Calling 查询学生画像与学习记录，再由 Qwen3 生成个性化回答

机制设计：将检索、学情查询、答案生成与批改判定拆为可观测子步骤，并通过 Supervised Fine-Tuning 强化专业领域表达，降低 hallucination 与知识点错配；作业批改覆盖 80% 常见题型

端云协同：在桌面端接入 NPU 加速本地推理，实现离线智能答疑；云端保留 FastAPI 推理服务与知识库更新链路，使本地低时延交互与中心化模型迭代能够协同演进

技术栈：Qwen3 · GraphRAG · Supervised Fine-Tuning · Large Language Model Agent / Tool Calling · NPU acceleration · FastAPI · Python

macOS 系统优化工具（SwiftSweep） ↗ Apple

个人独立项目 / 开源工具 · 2024.10 - 2024.12

项目定位：为解决 macOS 用户存储空间焦虑与常见清理工具高授权风险，基于 Swift 5.9 与 SwiftUI 独立开发集系统深度清理、相似文件检测与特权隔离于一体的原生维护工具（GUI + CLI），实现了 14+ 核心系统维护功能并成功完成 Apple 官方公证发布

架构与安全设计：摒弃传统清理软件索要全局 root 权限的危险模式，采用 XPC Helper + SMAppService 构建进程间通信隔离层，主应用在沙盒与受限权限下运行，彻底阻断了提权漏洞攻击面；设计了 dry-run 预演、基线白名单与严格的 symlink（符号链接）逃逸检测三重防护体系，实现 100% 零误删系统核心进程数据

算法与性能调优：面对数以万计的相似图片与视频检测导致的内存暴涨与 CPU 满载问题，引入基于 pHash（感知哈希）与 LSH（局部敏感哈希）降维检测算法；利用 Swift Task / Async 机制实现流式处理与内存回收，将重复媒体文件扫描速度提高了 3 倍，内存峰值控制在 200MB 以内

技术栈：Swift 5.9 / SwiftUI · XPC 进程间协议通信 · SMAppService · pHash / LSH 特征匹配算法 · Swift 包管理器 (SPM) · Developer ID 证书体系与 Notarization

基於 RISC-V 架构的五级流水线 CPU 设计 ↗ 系统

第七届全国大学生集成电路创新创业大赛（杯赛） · 核心开发 · 2023.01 - 2023.06

项目定位：从零开始使用 Verilog 基于 RISC-V (RV32I) 指令集架构，设计并实现了一颗完整的五级流水线 CPU，并成功在 FPGA 开发板上完成综合与功能验证，荣获全国总决赛二等奖

架构与冒险解决：独立完成了取指(IF)、译码(ID)、执行(EX)、访存(MEM)、回写(WB)核心数据通路的设计；面对流水线架构固有的数据冒险与控制冒险，设计了 Forwarding Unit（数据旁路转发单元）与 Hazard Detection Unit（流水线停顿检测单元），将核心运算指令在无冒险情况下的 CPI (每指令周期数) 稳定在 1.0

功能验证与完备性：构建了包含 50+ 汇编指令集的定制化测试激励（Testbench），涵盖了边界条件与复杂的分支跳转回归场景。通过 ModelSim 进行了指令级时序仿真验证，确认所有算术运算与跳跃指令行为符合 RISC-V 官方规范，保证了流片前 RTL 代码的高门级综合成功率

技术栈：Verilog HDL · RISC-V (RV32I) ISA · ModelSim / Vivado (仿真与综合) · FPGA 硬件开发

华为海思网络仿真平台重构与效能提升 系统

启明学院 Dian 团队 · 华为海思组核心研发 · 2023.03 - 2024.04

项目定位：主导华为海思内部底层网络仿真核心算法从自研平台向标准开源 NS-3 仿真环境的跨平台重构与迁移，保障了芯片研发与验证流程的不中断跨端迁移，将内部验证吞吐效率提升并深度融入了业界标准组件流

架构与特性适配：完成平台底层自底向上的跨版本重构（从 ns-3.31 强制演进至 ns-3.38），深入解析 Event Scheduler (事件调度器) 与 Time Model (时间步进模型) 内核代码。攻克了 C++ ABI 兼容性与内核对象生命周期管理痛点，大规模引入现代 C++ 智能指针体系接管手写内存释放，彻底消除了历史遗留的内存泄漏风险

工程化指标建设：针对复杂网络拥塞与拓扑场景，独立设计并开发了高精度的网络性能统计观测节点（Metrics Sink Modules），实现了对端到端时延、实时吞吐率、丢包率及多级队列占用率的毫秒级无切入式探针采集；在十万级并发包规模下，其统计开销占比低于总仿真时长的 5%，极大加速了拥塞控制算法与 PHY/MAC 层协议的调优迭代周期

技术栈：C++ (Modern C++ / STL) · ns-3 Discrete-Event Simulator内核机制 · Python 脚本自动化编排 · Linux (GDB/Valgrind 性能剖析) · TCP/IP 协议栈及多层拥塞模型

校园经历

启明学院 Dian 团队 · 华为海思组（技术）：将华为海思网络仿真算法移植至 NS-3 平台（C++），负责时延/端到端时延计算模块开发，深入理解 TCP/IP 协议栈与网络编程 | 媒体组（运营）：运营团队公众号

华中科技大学贵州省招生组 · 核心骨干：主导 500+ 人社群管理，组织线上线下宣讲，覆盖数百人